

黄瑞楠

电话: 18186971236 | 邮箱: 545551101@qq.com

籍贯: 湖北荆门 | 研究方向: 深度学习



教育经历

武汉工程大学 - 计算机技术 - 硕士(全日制)

2023年09月 - 2026年06月

湖北文理学院 - 物联网工程 - 本科(全日制)

2019年09月 - 2023年06月

项目经历

AI 商业智能助手(可演示)

项目定位: 基于 LangGraph 多智能体框架和增强型 RAG 系统的企业级商业智能助手, 实现分级权限知识库访问控制, 集成数据分析、知识检索和可视化功能, 支持自然语言交互进行业务数据查询和分析。(自然语言 → SQL + 知识库检索 + 自动可视化)

• 技术栈:

AI框架: LangGraph、LangChain、多模型支持 (OpenAI GPT/Qwen/Deepseek)

向量数据库: Milvus (分布式向量检索)、BGE-M3 混合嵌入模型

RAG技术: 5阶段增强检索 (相关性预检→查询改写→混合检索→结果融合→重排序)

前端: Streamlit (交互界面)、Highcharts 实时图表渲染

• 成果:

1. 多模态 AI Agent 架构设计

目标: 传统 BI 系统需要用户掌握 SQL, 且无法回答业务知识类问题。用户需要在多个系统间切换, 体验割裂。需要构建一个统一的智能助手, 支持自然语言查询数据库 + 知识库检索 + 数据可视化。提升系统易用性, 根据任务需求选择不同工作模式。

行动: 设计并实现基于 LangGraph 的状态机 workflow, 支持4种智能模式切换 (完整模式/数据分析/知识检索/纯对话)

开发 Text-to-SQL 引擎, 支持自然语言转复杂 SQL 查询; 实现自动化图表生成工具, 输出 (柱状图/饼图/折线图等)

采用工厂模式抽象 LLM/Embedding/VectorDB 层, 支持热切换多种模型提供商, 增强扩展性

会话状态跟踪:使用 Streamlit session_state 管理对话历史, 实现 Agent 重新初始化逻辑, DB/KB 状态变化时自动重建

2. 生产级 RAG 设计

目标: 传统单一向量检索存在语义偏移问题, 纯向量匹配无法理解用户意图, 导致检索召回率低, 用户体验差。企业知识库包含技术文档、政策文件、FAQ 等多种类型, 需要更智能的检索策略。

行动: 搭建增强型 RAG 管道:

• 相关性检查: 使用 LLM 判断查询是否与知识库相关 (过滤无关问题, 直接回答提高响应速度)

• 查询转换: 使用 LLM 从不同角度生成查询变体, 通过多样化的查询表述提升检索召回率。

• 混合检索: Dense (语义相似度) + Sparse (关键词匹配) 双路召回

• 结果合并: 合并多个检索结果列表, 进行去重和排序。用于多查询检索、多策略检索场景。

• 重排序: 使用LLM对初步检索结果进行二次评分和重排序, 通过 LLM 的语义理解能力, 显著提升 Top-K 结果的准确性。

• 上下文增强: 返回相邻 chunk, 解决上下文碎片化问题, 提供完整上下文, 增强答案连贯性。

自适应检索策略, 根据查询长度、复杂度自动选择最优策略 (简单|事实|对比|技术|复杂), 在成本和准确度间动态平衡, 智能路由到不同的RAG策略组合:

3. 分级权限知识库

目标: 企业知识库包含公开、内部、机密三类文档, 需要根据用户权限级别控制访问范围, 防止敏感信息泄露。

行动: 设计并实现基于角色的访问控制系统, 在向量数据库层面实现权限过滤, 确保从文档上传到检索全链路的权限一致性

4 知识库上传设计

目标: 清洗文本内容, 去除噪音数据, 提升数据质量。保留有效的中英文内容、代码块、结构化数据。

行动: 文本清洗 (去页码、URL、符号)、智能分割 (识别常见的结构化模式, 返回最适合的正则表达式分割模式)

实习经历

湖北亿纬动力 流程IT部-算法实习生

2025年04月 - 09月

• 数据库智能分析助手

使用Ollama+Dify, 构建数据库智能分析助手, 通过自然语言对话, 自动查询数据库生成图表进行可视化展示。

在Dify中配置Ollama作为后端LLM, 通过API调用本地Ollama服务, 设计数据库查询的完整workflow

技能

• 技能: 熟悉 Linux 环境编程、git基本命令和 git仓库的使用、Docker 容器化部署技术。

熟悉深度学习等领域的主流算法, 掌握模型搭建、训练优化调参、模型转化及部署技术。

熟悉大模型基础知识和技术, 如RAG、Agent, 能够使用langchain进行相关实验。